HADOOP 에서 HDFS에 읽었었는데,MONGODB파일을 HADOOP에서 불러오자.

Start a MongoDB container

> docker run -d --name mongodb -p 27017:27017 mongo

Explain what does the -p option does? Is the option mandatory to run instructions in the next slides?

In the installed MongoDB container, load movies.csv, tags.csv

이게 무엇인가? 이 OPTION이 왜 필요한것인가

1번 ANSWSER

DOCKER -P OPTION은 컨테이너 안에서 서비스를 구동하고, 외부에서 그 서비스에 접근하려고 할 때 사용한다. IP와 PORT로 그 컨테이너 안 서비스에 접속한다. 여기서는 27017:27017 中 첫 번째는 연결할 호스트의 포트 번호 이고, 뒤는 컨테이너의 포트 번호이다. 즉, -P 옵션은 컨테이너 포트를 열고 호스트 포트와 연결하는 옵션이다. 따라서 이 옵션을 사용하지 않았더라면, 뒤의 슬라이드를 진행하는데 어려움이 있다. 왜냐하면 MASTER NODE에서 컨테이너를 연결하고 실습을 진행하는 내용이기 때문이다.

Download mongo-hadoop library from slave nodes

\$ curl -fsSL \

 $https://raw.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo/download-hadoop-mongo-jar.sh \mid sudo sh \\ $ ls /usr/lib/hadoop-mapreduce/ \mid grep mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo/download-hadoop-mongo-jar.sh \mid sudo sh \\ $ ls /usr/lib/hadoop-mapreduce/ \mid grep mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo/download-hadoop-mongo-jar.sh | sudo sh \\ $ ls /usr/lib/hadoop-mapreduce/ \mid grep mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo/download-hadoop-mongo-jar.sh | sudo sh \\ $ ls /usr/lib/hadoop-mapreduce/ | grep mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/master/hadoop-mongo-isr.githubusercontent.com/kmu-bigdata/cloud-data-server/hadoop-mongo-isr.githubuser/hadoop-mongo$

Explain why the steps in page 10~12 are necessary.

2번 ANSWER

10~12P의 내용들은 HOST(LOCAL)에서 MONGOBD컨테이너에파일을 COPY하고 컨테이너에서는 MONGODB로 파일을 옮긴다. 그 후, 3개의 WORKER NODE에서 MONGOIMPORT를 하는데 여기서는 MONGODB에 데이터를 넣는 것이다. 후자의 경우는 WORKER NODE 3개에 걸쳐 모두 진행한다. 컨테이너의 경우는 모든 NODE에서 접근할 수 있지만 MONGO에서 처리할 데이터의 경우는 각 NODE마다 줘야 하기 때문이다.

Explain what this code does

큐트설

```
com.mongodb.hadoop.MongoInputFormat
 mport com.mongodb.hadoop.MongoOutputFormat;
import com.mongodb.hadoop.io.BSONWritable;
import com.mongodb.hadoop.util.MongoConfigUtil;
public class MovieIdByTags {
    public static void main(String[] args) throws Exception {
        Configuration conf = new Configuration();
          MongoConfigUtil.setInputURI(conf, "mongodb://" + args[0]);
MongoConfigUtil.setOutputURI(conf, "mongodb://" + args[1]);
          Job job = Job.getInstance(conf, "TagsAggregator");
          job.setJarByClass(MovieIdByTags.class);
          job.setMapperClass(Map.class);
          job.setCombinerClass(Combine.class);
          job.setReducerClass(Reduce.class);
          job.setMapOutputKeyClass(Text.class);
job.setMapOutputValueClass(Text.class);
          job.setOutputKeyClass(Text.class);
          job.setOutputValueClass(BSONWritable.class);
          job.setInputFormatClass(MongoInputFormat.<mark>class</mark>);
          job.setOutputFormatClass(MongoOutputFormat.class);
          job.waitForCompletion(true);
```

CAPTURE ANSWER

DRIVER CODE로서 각 단계의 입출력 형태를 지정한다. 이외에 기본적인 CONFIGURATION한다.

→ MONGODB와 HADOOP간의 DATA를 주고 받기 위해서 CONFIGURATION을 설정하고 관련 API를 IMPORT한다. MR 작업을 위해 JOB 한 개를 생성한다. (WORDCOUNT의 경우는 JOB2개를 만들었다. 마지막에 SORT를 위한 MR작업을 위해) 그 후, MOVIEIDBYTAGS클래스를 바탕으로 하는 JAR파일을 만들도록 설정한다. 이후, MAPPER, COMBINER, REDUCE작업에 대한 클래스를 연결한다. 또한 각 단계별 INPUT, OUTPUT FORMAT을 설정한다.

전체 MAP의 INPUT, OUTPUT TYPE은 TEXT로 설정한다.

SETMAPOUTPUTKEYCLASS와 SETMAPOUTPUTVALUECLASS에서는 MAP의 출력에 대한 것인데, TEXT 형태로 KEY, VALUE 를 RETURN 할 것을 말한다. 원래는 SETOUTPUTKEYCLASS 등을 이용해서 한 번에 작성하지만, MAP과 REUDCE의 TYPE이 다르기 때문에 따로 설정한다.

또한 SETOUTPUTKEYCLASS, SETOUTPUTKEYVALUECLASS를 통해서는 최종 결과물에 대해서 TYPE을 정하는데 KEY, VALUE를 KEY는 TEXT이고 VALUE는 BSONWRITABLE로 이진 JSON TYPE으로, SERIALIZATION가능한 TYPE으로 보낸다는 것이다.

마지막으로 SETINPUTFORMATCLASS, SETOUTPUTFORMATCLASS를 정의하는데 이는, 전체 입출력 DATA FORMAT을 MONGO_FORMAT으로 설정한다는 의미다.

MovieldByTags Map

Explain what this code does

CAPTURE ANSWER

→MAP에서는 MAP의 INPUT KEY, VALUE를 OBJECTID와 BSONOBJECT(BINARY JSON)TYPE으로 정하고 OUTPUT의 KEY, VALUE는 TEXT TYPE으로 정한다. 또한 변수를 설정하는데 TAGOUTPUT, MovieldOutput 은 text type의 상수형태다. MAP으로 들어오는 KEY-VALUE 입력에 대해서 TAG는 VALUE에서 TAG를 가져온 값을 STRING형태로 저장한다. 또한 MOVIEID에 MOVIEID를 가져와서 STRING형태로 가져온다. 그리고 TAG값을 tagoutput변수에 저장한다. 도한 movieldOutput변수에 movield값을 저장한다. 그 후에 tagsoutput과 movieldOutput을 저장한다. 즉, map의 결과로 return한다. 정리하자면 value로 오는 BSONObjet에 대해서 tag와 mvoidld값을 각각 tagoutput과 movieidoutput으로 저장한 후 key는 tagoutput value는 ovieldOutput을 저장하여 reutrn한다. 이 때 둘의 type은 text type이다.

Explain what Combiner does

Capture Answer

→먼저, combine이 MR PROGRAMMING에 있어서 어떤 역할을 하는지 설명하겠다. 이는 Optional 로서 Map의 결과를 Local Write하고 Reduce에 보내는 과정에 있어서 그 때 각 map의 결과를 합치는 것이다. 예를 들어서 고양이1, 고양이1, 강아지1 이라고 map의 결과가 나온다면, 고양이2 강아지1로 Map의 결과물들을 combine한다.

여기서의 Combine을 설명하자면, Input, Output의 key-value가 모두 Text type이다. 입력에 대해서 설명하자면 TYPE은 TEXT이지만, VALUE는 TEXT ITERABLE이다. 즉, KEY별로 VALUE를 ITERABLE하게 가지고 있다. 이것에 대해 TRAVERSE하는데, KEY마다 VALUE를 HASH자료구조에 STRING으로 바꾸어 저장한다. 또한 HASHSET에 대해서 ITERATOR를 이용해서 COMBINEROUTPUT변수에 HASH에 저장된 값을 저장한다. 그리고 해당 KEY(TAG)와 결과를VALUE(MOVIEID)로 RETURN한다.

MovieldByTags Reduce

Explain what this code does

CAPTURE ANSWER

→해당 코드는 REDUCE 과정이다. REDUCE의 INPUT가 OUTPUT KEY-VALUE는 INPUT의 경우는 COMBINE과정을 거친 것으로 KEY와 VALUE는 TEXT이다. 또한 OUTPUT의 KEY는 TEXT이고 VALUE는 BSONWRITABLE TYPE으로써 BINARY JSON TYPE이다. KEY(TAG)마다 가진 MOVIEID(ITERABLE MOVIEID)를 읽어서 HASHSET에 저장한다. (이 때, SET이므로 중복이 없다.) 그리고 HASHSET을 ITERATOR로 TRAVERSE하면서 STRINGBUILDER TYPE가진 SB변수에 STRING TYPE으로 MOVIEID를 APPEND해서 저장한다. 또한 MOVIEIDS라는 STRING에 MOVIEID를 APPEND해서 저장한 SB를 저장한다. 그 후, 해당 STRING TYPE의 MOVIEIDS가 "," 형태로 끝난다면 그 앞까지 잘라서 MOVIEIDS에 저장한다. 그 후, BASICBSONOBJECT에 "MOVIEIDS"이름으로 앞의 과정 결과를 저장한다. 그 후 BSONWRITABLE TYPE형식에 맞게 SETDOC함수를 통해 저장하고 REDUCE를 마친다.

결과, TAG별 MOVIEID 모음이 저장된다. (BSON TYPE을 MONGODB로 읽어서 출력해볼 수 있다)

Capture the screen of MongoDB outputs of

movielens.tags_out table

-capture결과- -

```
m 0
                          1:1
out.find(())
"1950's Superman TV show", "moivelds": "47950")
""The Bunter("", "moivelds": "100108, 26172, 2490")
"\"had CIA\"-- too simplistic", "moivelds": "7445")
"\"bad CIA\"-- too simplistic", "moivelds": "7445")
"\"bad CIA\"-- too simplistic", "moivelds": "6746")
"\"baitchy\"-", "moivelds": "111800, 926")
"\"sinjing by non-singers\" in The Wrer 24/31 Dec 2012", "moivelds": "
               id" : "'I Had No Idea That You Were A F***** Vampire!'", "moiveIds" : "49961
                         : "'It's Not Where Your Dreams Take You But Who You Take In Your Dreams'
', "moiveIds" : "2076" }
: "'Show Me The Money! I Can't Hear You Haji Scream Louder!'", "moiveIds"
                           4" }
: "'Wow Mrs. Robinson Your Porridge Is Just Right!'", "moiveIds" : "1247"
              28, 27671, 31247, 73290, 2930, 3303, 57972, 8954, 54426, 52528, 37626, 7949, 3192
1"]
{ "id": "04/11", "moiveIds": "6075, 8777, 26797, 41712, 48909, 60904, 32280, 5
6370, 82667, 79533, 60990, 37976, 44655, 42551, 26049, 25751, 26602, 79760, 54241
, 31188, 59655, 48575, 8856, 27370, 53835, 47084, 8794, 6133, 47239, 61742, 41815
, 59549, 81910, 27067, 84187, 7113, 44597, 25972, 33340, 80648, 9011, 27515, 2775
8, 50583, 58223, 76158, 26025, 60384, 8954, 73609, 53373, 8057, 8611, 6151, 45837
, 26998, 50594, 79578, 26596, 60551, 77833, 34548, 74727, 72142, 47728, 27738, 27
736, 59976, 23252, 53355, 58808, 44568, 5520, 70015, 71189, 4431, 69949, 41336, 7
7293, 39918, 25881, 77854, 6688, 45891, 6206, 4668, 48638, 5130, 40591, 47146, 81
817, 26228, 34238, 31247, 60103, 33264, 57972, 78898, 60461, 7949, 7828" }
{ "id": "05.099", "moiveIds": "27416" }
{ "id": "05.099", "moiveIds": "27416" }
Type "it" for more
> exit()
2018-11-21709;20:05.275+0000 E QUERY [js] ReferenceError: exit is not defined: exit open.
     ye
bot@c714fed85635:/# pwd
     oot@c714fed85635:/# exit
     ---rax08050kmubigdata-cluster-m:~$ pwd
home/choirak0805
                                                                                                                              PWD명령으로 HOST이름 최락준
```

1. Using the movielens dataset, write a MongoDB query and Hive query to count the number of unique movie names (movies.csv)


-HIVE-


```
hive> select count(distinct title) from movies;
WARNING: Hive-on-MR is deprecated in Hive 2 and may not be available in the future versions. Con
sider using a different execution engine (i.e. spark, tez) or using Hive 1.X releases.
Query ID = choirak0805_20181122095055_d4a30479-3e2b-420a-8929-8d9d2f4a313b
Total jobs = 1
Launching Job 1 out of 1
Number of reduce tasks determined at compile time: 1
In order to change the average load for a reducer (in bytes):
 set hive.exec.reducers.bytes.per.reducer=<number>
In order to limit the maximum number of reducers:
 set hive.exec.reducers.max=<number>
In order to set a constant number of reducers:
set mapreduce.job.reduces=<number>
Starting Job = job_1542770342773_0002, Tracking URL = http://kmubigdata-cluster-m:8088/proxy/app
lication_1542770342773_0002/
Kill Command = /usr/lib/hadoop/bin/hadoop job -kill job_1542770342773_0002
Hadoop job information for Stage-1: number of mappers: 1; number of reducers: 1
2018-11-22 09:51:07,822 Stage-1 map = 0%, reduce = 0%
2018-11-22 09:51:17,317 Stage-1 map = 100%, reduce = 0%, Cumulative CPU 3.45 sec
2018-11-22 09:51:24,660 Stage-1 map = 100%, reduce = 100%, Cumulative CPU 5.87 sec
MapReduce Total cumulative CPU time: 5 seconds 870 msec
Ended Job = job 1542770342773 0002
MapReduce Jobs Launched:
Stage-Stage-1: Map: 1 Reduce: 1 Cumulative CPU: 5.87 sec HDFS Read: 1385885 HDFS Write: 105
SUCCESS
Total MapReduce CPU Time Spent: 5 seconds 870 msec
27263
Time taken: 30.505 seconds, Fetched: 1 row(s)
hive>
```


-MongoDB-


```
local 0.000GB
movielens 0.025GB
> use movielens
switched to db movielens
> db.movies.distinct("title").length
2/262
> RESULT
```

2. Implement Hadoop MapReduce code to	count the number of unique movie	
names		









3. Using the movielens dataset, write a MongoDB query and Hive query to Count the number of movies whose genre contains a word "Film-Noir" (movies.csv)

-HIVE-

```
Cholealogo(Spikmubligatas-duter-m:~/hW_G_3/MPQQ4 - Chrome

A https://ssh.cloud.google.com/projects/sound-decoder-221702/zones/asia-northeast1-c/instances/kmubigdata-cluster-m?authuser=1&hl=ko&projectNumber=176045424343

**Course**
**Lines**
**Lin
```

-MongoDB—


```
> db.movies.aggregate([ {$project:{genre:{$split:["$genres","|"]}}}, {$match:{genre:"Film-Noir"}}, {$group:{_id:null,Film_Noir:{$sum:1}}}, {$project:{_id:0}}})  


{ db.movies.aggregate([ {$project:{genre:{$split:["$genres","|"]}}}, {$match:{genre:"Film-Noir"}}, {$group:{_id:null,Film_Noir:{$sum:1}}}, {$project:{_id:0}}})  


{ "Film Noir": 330 }

}
```

4. Implement Hadoop MapReduce code to count the number of movies whose genre
contains a word "Film-Noir" (movies.csv)







5. Using the movielens dataset, write a MongoDB query and Hive query to list the tag that are cited the most (tags.csv)

-HIVE-

```
📫 choirak0805@kmubigdata-cluster-m: ~/cloud-data-server/hive - Chrome
                                                                                                                                                                                                    \times
     https://ssh.cloud.google.com/projects/sound-decoder-221702/zones/asia-northeast1-c/ins...
hive> select tag,count(*) as numoftag from tags group by tag order by numoftag desc limit 1;
WARNING: Hive-on-MR is deprecated in Hive 2 and may not be available in the future versions. Con sider using a different execution engine (i.e. spark, tez) or using Hive 1.X releases.

Query ID = choirak0805_20181122100910_73064db4-daee-4d09-8608-e5fa402166df

Total jobs = 2

Launching Job 1 out of 2
Number of reduce tasks not specified. Estimated from input data size: 1 In order to change the average load for a reducer (in bytes):
set hive.exec.reducers.bytes.per.reducer=<number>
In order to limit the maximum number of reducers:
    set hive.exec.reducers.max=<number>
 In order to set a constant number of reducers:
set mapreduce.job.reduces=<number>
set mapreduce.job.reduces=<number>
Starting Job = job _1542770342773_0004, Tracking URL = http://kmubigdata-cluster-m:8088/proxy/app lication_1542770342773_0004/
Kill Command = /usr/lib/hadoop/bin/hadoop job -kill job_1542770342773_0004
Kill Command = /usr/lib/hadoop/bin/hadoop job -kill job_1542770342773_0004

Hadoop job information for Stage-1: number of mappers: 1; number of reducers: 1
2018-11-22 10:09:22,529 Stage-1 map = 0%, reduce = 0%
2018-11-22 10:09:29,991 Stage-1 map = 100%, reduce = 0%, Cumulative CPU 4.06 sec
2018-11-22 10:09:36,254 Stage-1 map = 100%, reduce = 100%, Cumulative CPU 6.53 sec
MapReduce Total cumulative CPU time: 6 seconds 530 msec
Ended Job = job_1542770342773_0004
Launching Job 2 out of 2
Number of reduce tasks determined at appril 1.5.
Number of reduce tasks determined at compile time: 1
In order to change the average load for a reducer (in bytes):
 set hive.exec.reducers.bytes.per.reducer=<number>
In order to limit the maximum number of reducers:
    set hive.exec.reducers.max=<number>
set hive.exec.reducers.max=<number>
In order to set a constant number of reducers:
set mapreduce.job.reduces=<number>
Starting Job = job_1542770342773_0005, Tracking URL = http://kmubigdata-cluster-m:8088/proxy/app lication_1542770342773_0005/
Kill Command = /usr/lib/hadoop/bin/hadoop job -kill job_1542770342773_0005
Hadoop job information for Stage-2: number of mappers: 1; number of reducers: 1 2018-11-22 10:09:45,085 Stage-2 map = 0%, reduce = 0% 2018-11-22 10:09:51,429 Stage-2 map = 100%, reduce = 0%, Cumulative CPU 2.6 sec 2018-11-22 10:09:57,678 Stage-2 map = 100%, reduce = 100%, Cumulative CPU 4.2 sec MapReduce Total cumulative CPU time: 4 seconds 200 msec Ended Job = job_1542770342773_0005
MapReduce Jobs Launched:
 MapReduce Jobs Launched:
 Stage-Stage-1: Map: 1 Reduce: 1 Cumulative CPU: 6.53 sec HDFS Read: 16611456 HDFS Write: 13
 Stage-Stage-2: Map: 1 Reduce: 1 Cumulative CPU: 4.2 sec HDFS Read: 1324238 HDFS Write: 111
SUCCESS
 Total MapReduce CPU Time Spent: 10 seconds 730 msec
rime taken: 48.293 seconds, Fetched: 1 row(s)
```

-MongoDB--

```
{ "FILM_NOIF" : 14 }
> db.tags.aggregate([
... {$group:{_id:"$tag",numoftag:{$sum:1}}},
... {$sort:{numoftag:-1}},
... {$limit:1}])
{ "_id" : "sci-fi", "numoftag" : 3384 }
> 20142770 ChoiRakJun To Certification
```

Complement Hadaan Man Badaan and to list the ten that one site of the most
6. Implement Hadoop MapReduce code to list the tag that are cited the most (tags.csv)
(tags.csv)

